

지시문의 모호성은 요약 과제의 할루시네이션을 늘리는가

작성자: 김대훈

작성일: 2026년 9월 21일

초록

AI에게 작업 지시를 모호하게 준 경험이 실제로 할루시네이션(사실이 아닌 내용 생성)으로 이어진 사건을 계기로, "지시문이 모호할수록 AI 응답에 할루시네이션이 늘어난다"는 가설을 세웠다. 검증을 위해 짧은 가상의 프로젝트 로그(19개의 확인 가능한 사실 포함)를 준비하고, 이를 "요약해줘"라는 모호한 지시와 "문서에 있는 내용만, 없으면 없다고 써라"는 구체적 지시로 각각 10회씩 반복 제시해 응답을 모았다. 각 응답을 사실 목록과 대조한 결과, 모호 조건에서는 할루시네이션이 전혀 발견되지 않았고(0/10), 구체 조건에서도 1건(1/10)만 발견됐다. 그마저도 새로운 사실을 지어낸 것이 아니라, 문서에 있는 정보를 "문서에 없음"이라고 잘못 표시한 과잉 방어형 오류였다. 이 결과는 원래 가설을 뒷받침하지 않는다. 정보가 모두 모델의 컨텍스트 안에 주어지는 단순 요약 과제에서는 지시문의 모호성이 할루시네이션에 뚜렷한 영향을 주지 않을 수 있으며, 오히려 반할루시네이션 지시가 새로운 유형의 오류(과잉 방어)를 만들 가능성이 있다는 것을 확인했다.

1. 서론

1.1 문제의식

2026년 9월 11일, 실제 작업 중 AI에게 지시사항을 모호하게 준 탓에 AI가 실제로 존재하지 않는 내용을 답하는 할루시네이션이 발생해 프로젝트가 중간 단계에서 막힐 뻔한 일이 있었다. 즉시 지시를 다시 명확히 내려(재지시) 해결했지만, 이 경험은 "지시문의 모호성과 AI의 할루시네이션 사이에 실제로 관계가 있는가"라는 질문으로 이어졌다.

1.2 가설을 세우기까지

관심 분야(LLM 활용·프롬프트) 안에서 AI와 함께 확인 가능한 질문 10개를 뽑았다. 이 중 데이터를 직접 모을 수 있는 것만 추리는 과정에서 아래 3개는 아까웠지만 접었다.

- 체크리스트 유무 → 중단 없이 완주: "완주"를 객관적으로 판정할 기준이 모호해 측정이 어려워 접었다.
- 반복 수정 시 수정량 감소: 회차가 순차적으로 쌓여야 해서 짧은 기간에 다수 시행을 모으기 어려워 접었다.
- 역할 부여 유무 → 응답 품질: "품질"을 숫자로 잴 기준이 모호해 접었다.

최종적으로 "지시문의 모호성이 할루시네이션에 영향을 준다"는 주제를 골랐다. 실제 겪은 사건과 가장 직접적으로 연결되고, 일주일 안에 직접 실행·검증할 수 있으며, 결과가 어느 방향으로 나오든 의미가 있었기 때문이다.

1.3 가설

AI에게 주는 작업 지시문이 모호할수록, 응답에 원문(주어진 자료)에 없는 내용(할루시네이션)이 포함되는 개수가 늘어난다.

- 무엇이 무엇에 영향을 주는가: 지시문의 모호성(원인) → 응답 속 할루시네이션 개수(결과)
- 가설이 틀렸다면: 두 조건 간 할루시네이션 개수에 유의미한 차이가 없거나, 오히려 구체적 지시 조건에서 더 많이 나올 것이다.

2. 방법

2.1 선행 연구 검토

가설을 세우기 전, AI에게 관련 선행 연구를 물어본 뒤 각 항목을 제목으로 직접 검색해 실제 존재 여부·저자·발표연도·초록을 대조했다. 5건을 확인했고(\$4 참고문헌), 검증 중 원문 접속이 막혀 확인할 수 없었던 문헌 1건은 목록에서 제외했다.

이미 알려진 사실로는, 할루시네이션이 널리 연구된 문제라는 점(Ji et al., 2023), 요약 과제에서 원문에 없는 내용이 실제로 생성될 수 있다는 점(Mayne et al., 2020), 안전 지침이 강할수록 무해한 요청까지 과도하게 회피하는 "과잉 방어" 현상이 있다는 점(Röttger et al., 2024), 할루시네이션이 프롬프트 때문인지 모델 자체 때문인지 구분하려는 시도가 있다는 점(Dang et al., 2025), 지시문 복잡성만으로는 요약 할루시네이션이 뚜렷하게 줄지 않을 수 있다는 점(Jaaouine & King, 2025)이 있다.

이번 연구에서 새로 주장하는 것은, 원문이 모델 컨텍스트에 그대로 주어지는 단순 요약 과제에서는 지시문 모호성의 영향이 미미할 수 있다는 것, 그리고 반할루시네이션 지시가

안전성 맥락이 아닌 사실 확인 맥락에서도 과잉 방어형 오류를 만들 수 있다는 것이다.

2.2 실험 설계

항목	내용
독립변수 (바꾼 조건)	지시문의 구체성 — "모호" / "구체"(반할루시네이션 지시 포함) 2수준
고정 조건	소스 문서(가상의 프로젝트 로그, 약 800자, 19개의 확인 가능한 사실 포함), 모델(Claude, Sonnet 계열), 각 시행은 이전 시행을 기억하지 못하는 독립된 새 대화/맥락에서 진행
반복 횟수	조건당 10회, 총 20회
측정값	응답 1건당, 소스 문서의 사실 목록과 대조해 (a) 원문에 없는 사실이 새로 등장한 개수 + (b) 원문의 값을 틀리게 옮긴 개수의 합
공개 데이터 여부	사용 안 함. 소스 문서는 실험을 위해 직접 작성한 가상 자료

지시문 두 버전은 다음과 같다.

- 모호 버전: "이 문서 요약해줘." + 문서 원문
- 구체 버전: "아래 문서에 있는 내용만 사용해서 5줄 이내로 요약해줘. 문서에 없는 숫자, 이름, 날짜, 파일명은 절대 새로 만들어 넣지 마. 확실하지 않은 부분이 있으면 추측하지 말고 '문서에 없음'이라고 써." + 문서 원문

2.3 실행 및 채점

최초 계획은 Anthropic API를 자동 호출하는 방식이었으나, 키 발급 과정에서 화면 캡처로 키가 노출되는 사고가 있었고 소규모 실험 대비 크레딧 결제·키 보안 관리 부담이 크다고 판단해, 매번 독립된 새 대화 맥락에서 반복 실행하는 방식으로 바꿨다. 20회 반복 전송은 Claude Code 세션의 서브에이전트 기능으로 실행했으며, 각 서브에이전트는 이전 시행을 전혀 기억하지 못하는 새 맥락에서 실행돼 독립성 조건을 유지했다.

채점은 각 응답을 사실 목록(정답표)과 하나씩 대조하는 방식으로 진행했다. 1차 대조는 AI가 수행했고, 그 결과를 연구자가 직접 검토·확정했다.

3. 결과

조건	반복 수	할루시네이션 발생 시행 수	평균 개수
모호	10	0건	0.0
구체 (반할루시네이션 지시)	10	1건	0.1

모호 조건 10개 응답 전부, 소스 문서의 19개 사실과 정확히 일치했다 — 발견되지 않은 내용이나 틀리게 옮긴 값이 없었다.

구체 조건에서는 9개 응답이 정확했고, 1개 응답([specific_03](#))에서 오류가 발견됐다. 이 응답은 문서에 실제로 있는 정보("원래 4월 10일 연동 완료 예정")를 "문서에 없음"이라고 잘못 표시했다. 이는 새로운 사실을 지어낸 전형적 할루시네이션이 아니라, "확실하지 않으면 없다고 써라"는 지시를 과도하게 따른 결과로 보인다. 반대로 같은 조건의 다른 두 응답([specific_01](#), [specific_05](#))은 문서에 실제로 없는 정보(연동 지연 후의 새 완료 예정일, 지연 기간)를 정확히 "문서에 없음"으로 표시해, 같은 지시가 항상 오류를 만드는 것은 아니었다.

전체 원자료는 [원자료/raw_responses/](#)에, 채점 근거는 [원자료/채점표.csv](#)에 있다.

4. 논의

4.1 가설을 뒷받침하는가

뒷받침하지 않는다. 모호 조건의 할루시네이션이 구체 조건보다 오히려 적었고(0건 대 1건), 통계적으로 의미 있는 차이라고 보기도 어렵다. 이 데이터만 놓고 보면 "지시문의 모호성이 할루시네이션 발생량을 좌우한다"는 최초 가설은 기각해야 한다.

4.2 다르게 나온 이유

- 1 과제 난이도가 낮았을 가능성: 소스 문서가 짧고, 모델의 컨텍스트에 그대로 주어진 "책을 펴놓고 보는" 형태의 요약 과제였다. 이런 조건에서는 지시문이 모호해도 모델이 원문을 그대로 참조할 수 있어 굳이 지어낼 필요가 없었을 것이다. Dang et al.(2025)의 틀을 빌리면, 이번 과제는 "프롬프트 민감도(Prompt Sensitivity)가 낮은" 유형이었을 가능성이 있다.
- 2 반할루시네이션 지시의 부작용 가능성: 구체 조건에서 발생한 유일한 오류가 "과잉 방어"였다는 점은, "확실하지 않으면 없다고 써라"는 지시가 실제로 있는 정보까지 없다고 오판하게 만들 수 있음을 시사한다. Röttger et al.(2024)이 안전성 맥락에서 확인한 과잉 방어(exaggerated safety) 현상과 유사한 메커니즘이 사실 확인 맥락에서도 나타날 수 있다는 것인데, 표본이 1건뿐이라 단정할 수는 없다.

- 3 표본 수가 적어 우연에 가까운 차이일 가능성: 조건당 10회는 과제의 최소 기준을 충족하지만, 통계적으로 안정적인 차이를 보기엔 여전히 적다. 0건과 1건의 차이는 우연히 뒤집힐 수 있는 수준이다.

4.3 가설을 고친다면

- 고치기 전: "AI에게 주는 작업 지시문이 모호할수록, 응답에 원문에 없는 내용(할루시네이션)이 포함되는 개수가 늘어난다."
- 고친 후(제안): "정보가 모두 컨텍스트 안에 주어진 단순 요약 과제에서는 지시문의 모호성이 할루시네이션 발생률에 뚜렷한 영향을 주지 않는다. 오히려 '문서에 없으면 없다고 써라'는 반할루시네이션 지시가, 실제로 있는 정보를 없다고 잘못 판단하는 과잉 방어 오류를 만들 수 있다."

4.4 결론

이번 실험은 애초 세운 가설("지시문이 모호할수록 할루시네이션이 늘어난다")을 뒷받침하지 못했다. 오히려 반대 방향에 가까운 결과(모호 조건 0건, 구체 조건 1건)가 나왔고, 그 유일한 오류도 지어낸 사실이 아니라 반할루시네이션 지시가 유발한 과잉 방어형 오류였다. 이는 할루시네이션이 지시문의 모호성 하나만으로 설명되는 단순한 현상이 아니라, 과제의 성격(원문 접근 가능 여부)과 지시문의 종류(무엇을 요구하는가)에 따라 달라지는 복합적인 현상임을 시사한다. 특히 "안전하게 답하라"는 지시가 안전성 맥락뿐 아니라 사실 확인 맥락에서도 과잉 방어를 유발할 수 있다는 관찰은, 기존 문헌이 다루지 않은 지점으로 후속 연구에서 더 큰 표본과 더 어려운 과제로 검증해 볼 가치가 있다.

4.5 한계

- 표본이 조건당 10회로 적어, 통계적으로 안정된 결론이라 보기 어렵다.
- 소스 문서 하나, 과제 유형(짧은 문서 요약) 하나에서만 실험했다. 컨텍스트에 없는 지식을 묻는 과제 등 다른 유형에서는 결과가 다를 수 있다.
- 할루시네이션 채점을 AI가 1차로 수행하고 연구자가 최종 검토하는 방식으로 진행했다 — 완전히 독립적인 제3자 채점은 아니다.
- `specific_03`의 과잉 방어 오류는 1건뿐이라 일반화하기 어렵다.

5. 참고문헌

- 1 Ji, Z., Lee, N., Frieske, R. M., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12).
- 2 Maynez, J., Narayan, S., Bohnet, B., & McDonald, R. (2020). On Faithfulness and Factuality in Abstractive Summarization. *Proceedings of ACL 2020*.
- 3 Röttger, P., Kirk, H., Vidgen, B., Attanasio, G., Bianchi, F., & Hovy, D. (2024). XSTest: A Test Suite for Identifying Exaggerated Safety Behaviours in Large Language Models. *Proceedings of NAACL 2024*.
- 4 Dang, A.-H., Tran, V., & Nguyen, L.-M. (2025). Survey and analysis of hallucinations in large language models: attribution to prompting strategies or model behavior. *Frontiers in Artificial Intelligence*.
- 5 Jaaouine, I., & King, R. D. (2025). Mitigating Hallucinations in Zero-Shot Scientific Summarisation: A Pilot Study. *arXiv:2512.00931 (프리프린트)*.

6. 재현 방법

- 1 원자료/source_document.md를 연다 — 실험에 쓴 가상 소스 문서다.
- 2 원자료/복사용_프롬프트_모호.txt와 원자료/복사용_프롬프트_구체.txt를 각각 새 대화(맥락)에 그대로 붙여넣어 10회씩 응답을 받는다. 반드시 매번 새 대화로 열어야 시행이 서로 독립적이다.
- 3 받은 응답을 원자료/raw_responses/에 vague_01.txt~vague_10.txt, specific_01.txt~specific_10.txt 형식으로 저장한다.
- 4 원자료/사실목록(정답표).md의 19개 항목과 각 응답을 대조해 원자료/채점표.csv에 할루시네이션 개수를 기록한다.
- 5 (참고용, 이번 실험에는 미사용) API로 자동화하려면 scripts/run_experiment.py를 참고한다. ANTHROPIC_API_KEY 환경변수와 pip install anthropic이 필요하다.

7. AI에게 맡긴 일과 직접 판단한 일

AI(Claude)에게 맡긴 일

- 관심 분야 안에서 후보 질문 10개 브레인스토밍
- 실험용 가상 소스 문서·정답표·복사용 프롬프트 작성
- 20회 반복 시행 실행(서브에이전트를 통한 반복 전송)과 사실 대조 1차 채점
- 선행 연구 후보 검색과 초록 요약

- 결과 해석 초안 작성

본인(김대훈)이 직접 판단한 일

- 관심 분야와 실제 경험(2026-09-11 사건)을 바탕으로 연구 방향을 정함
- 10개 후보 중 접을 것과 남길 것을 고르고, 최종 가설을 확정함
- 측정 방법(문헌 인용형 vs 고정 문서 요약형)과 실행 방식(API vs 수동/서브에이전트)을 최종 선택함
- AI가 검색해 온 선행 연구 5건이 실제로 존재하는지, 가설과 어떻게 연결되는지 최종 확인함
- AI가 1차로 채점한 할루시네이션 결과와 해석 초안을 직접 검토하고 승인함
- 가설이 데이터를 뒷받침하지 않는다는 최종 판단과 결론을 확정함